



REGIME

V4.0.0

DEPLOYMENT PRESENTATION

LOGISTIC RÉGIME-CONDITIONNELLE · HMM 4 ÉTATS · MACRO FUSION

AUDIENCE

ENG COMMODITIES COMPASS

STATUT

VALIDATION R&D

MAI 2026

SOMMAIRE

Table des matières

01	TL;DR	p. 03
02	Pourquoi cette release ?	p. 05
03	Comment ça marche, pédagogiquement	p. 07
04	Ce qu'on déploie concrètement	p. 11
05	Validation & rollout	p. 14
06	Critères de succès chiffrés	p. 16
07	Limitations honnêtes	p. 19
08	Annexes	p. 21

AUDIENCE Équipe ingénierie commodities-compass.

OBJET Présenter le design et les critères de validation du nouvel algo `regime v4.0.0` — logistic régime-conditionnelle avec HMM 4 états et fusion macro LLM. À valider avant tout déploiement shadow.

COMPANION DOCS Plan original `docs/plans/2026-04-01-compass-v2-logistic-engine.md` ; synthèse comparative `docs/COMPASS_V2_VS_EXP033_SYNTHESIS.md` ; rapport R&D complet `docs/R&D_CACAO_FINAL_REPORT.md` .

STATUT Validation R&D — déploiement **conditionné** à l'atteinte des critères pre-registered (cf. § 6).

01 · SYNTHÈSE

TL;DR

Après `accuracy v3.0.0`, on attaque le plafond de précision identifié dans la release précédente (~60% sur le feature set polynôme). L'approche est **radicalement différente** : au lieu d'enrichir un polynôme global, on **conditionne** le modèle au régime de marché détecté chaque jour, et on fitte une logistic distincte par régime. La logique est issue de six mois de notebooks R&D (EXP-002 à EXP-032) qui ont montré qu'un même indicateur peut être bullish en régime Normal et bearish en régime Bull — un seul jeu de poids global est donc structurellement sous-optimal.

1. **Étape 1 — Détection de régime (HMM)**. Un Hidden Markov Model gaussien à 4 états (Crash / Normal / Burst / Bull) tourne en Viterbi sur les 252 derniers returns chaque nuit, et émet à la fois `regime_id` et `P(regime)`. Quatre régimes parce que BIC le dicte (delta=934 vs 2 états, EXP-005).
2. **Étape 2 — Logistic régime-conditionnelle**. Pour chaque régime, une régression logistique L2 prédit `P(down)` à J+1 à partir de 10 delta features techniques (variations sur 3 jours plutôt que niveaux — plus robustes aux ruptures, EXP-010 +6pp). Pass 1 sans macro.
3. **Étape 3 — Fusion macro LLM**. Pass 2 ré-évalue `P(down)` en ajoutant 3 features macro produites par le LLM nightly (sentiment, supply/demand, climate risk). La décision finale **HEDGE** **MONITOR** **OPEN** sort des seuils `open_threshold` et `hedge_threshold` calibrés **par régime**.

Le nouvel algo s'appelle `regime v4.0.0`. Côté livraison : 3 nouveaux modules backend (`regime.py`, `delta_features.py`, `logistic.py`), 1 nouvelle table DB (`pl_regime_state`), 2 dépendances Python (`hmmlearn`, `scikit-learn`). Inférence quotidienne < 100 ms ; entraînement offline trimestriel ~30 min.

Mais — et c'est le point fondamental — on ne shippe PAS si la R&D ne valide pas l'hypothèse. Les critères de succès sont pre-registered (§ 6) : delta vs Always-HEDGE $\geq +5pp$ avec IC 95% excluant zéro, et delta sur holdout strict (374 jours, jamais touché en tuning) $\geq 50\%$ du delta sur train. Si l'un des deux échoue → fallback sur Algo B (EXP-033). C'est une release **scientifique avant d'être technique**.

HYPOTHÈSE À VALIDER

Le signal directionnel daily n'est pas zéro — max `|p|=0.06` par feature individuelle, mais une combinaison non-linéaire régime-conditionnelle peut extraire $\geq +5pp$ au-dessus de Always-HEDGE avec IC excluant zéro.

Si l'hypothèse se confirme (delta $\geq +5pp$, CI exclut zéro, sur 2024–2026) → on a un signal directionnel daily réel et tradeable, et `regime v4.0.0` remplace progressivement `accuracy v3.0.0`.

Si l'hypothèse s'infirme (CI inclut zéro ou dégradation post-2024) → le plafond directionnel à

~52% est confirmé, et l'approche **EXP-033 (Algo B)** devient le défaut. Pas de honte à shipper le bon algo.

RÉGIMES 4 HMM gaussien · Viterbi	FEATURES 13 10 tech delta + 3 macro	PARAMS TOTAL ~72 ratio obs/params 21:1
---	--	---

02 · CONTEXTE

Pourquoi cette release ?

Là où s'arrête v3

La release `accuracy v3.0.0` (déployée mai 2026) a fait passer la précision walk-forward de ~30% à 60% via un pipeline polynôme + GBM gate. Mais elle a aussi documenté très clairement **son propre plafond** : le feature set (16 indicateurs techniques z-scorés) sature à ~60% de précision parce que chaque feature individuellement contient peu de signal directionnel — le maximum observé sur l'historique 2016–2026 est $|p|=0.06$ en corrélation univariée. Casser ce plafond demande de changer de paradigme, pas d'ajuster les coefficients.

Trois directions ont été explorées en R&D pour aller plus haut :

1. **Enrichir le feature set (OI delta, term structure, COT positioning)** — direction prometteuse mais coût d'intégration moyen et résultats incertains seuls.
2. **Conditionner au régime de marché** (cette release) — la même feature peut avoir un signe inversé selon le régime (rank corr Normal vs Bull = 0.024 — donc presque indépendantes, EXP-008 / FI-003).
3. **Passer en mode défensif structurel (Algo B / EXP-033)** — Always-HEDGE optimisé, accepte le plafond ~52% comme borne dure et optimise la couverture.

`regime v4.0.0` instancie la direction 2. Si elle ne tient pas ses promesses sur holdout, la direction 3 reste le plan B documenté.

Pourquoi le régime change tout

Le constat empirique fondateur : un même indicateur technique (par exemple `macd`) n'a pas la même valeur prédictive selon que le marché est en régime Normal (76.6% du temps), Bull (18.7%), Burst (4.4%) ou Crash (0.3%). En Normal, un MACD positif tend à anticiper une légère baisse à J+1 (mean-reversion). En Bull, le même MACD positif tend à confirmer la tendance (continuation). Un modèle global avec un seul jeu de poids ne peut au mieux qu'apprendre la moyenne pondérée des deux comportements — et donc être faux dans les deux régimes.

EXP-008 a quantifié cet effet : la **corrélation de rang des feature importances entre Normal et Bull est de 0.024**. Concrètement, l'ordre des features-qui-comptent est presque indépendant entre régimes. Une logistique distincte par régime est donc justifiée mathématiquement, pas seulement par esthétique.

Pourquoi maintenant

BRIQUE R&D	STATUT	RÉFÉRENCE
Détection HMM 4 états (BIC delta=934 vs 2 états)	Validé offline	EXP-005
Set réduit à 10 indicateurs (vs 14, 6–7 dim indep)	Validé offline	EXP-002 / EXP-008
Delta features 3j (+6pp vs niveaux post-rupture)	Validé offline	EXP-010
Z-score 252j (corrige look-ahead)	Validé offline	EXP-027
Régime-conditional weights (rank corr 0.024)	Validé offline	EXP-008 / FI-003
Decision functions (regime ensemble +3.1pp)	Validé offline	EXP-009

Toutes les briques sont vertes individuellement. Cette release est le premier **assemblage en pipeline production** et le premier passage à la validation walk-forward stricte avec holdout 2024-09 → 2026-04 (374 jours jamais touchés). C'est le bon moment parce qu'on a maintenant : (i) v3 en production qui sert de baseline mesurable, (ii) une stack DB et un nightly bien rodés grâce à v3, (iii) un holdout suffisant pour conclure (cf. § 6).

03 · ARCHITECTURE

Comment ça marche, pédagogiquement

Le pipeline se lit en quatre étapes successives qui transforment OHLCV brut en décision. Chacune fait une chose et une seule, ce qui rend les pannes faciles à isoler et chaque couche testable en unité. L'ordre est important : la détection de régime arrive **avant** la prédiction directionnelle, pas après — ce qui distingue cette release de toutes les approches précédentes où le régime était au mieux une feature de plus dans un modèle global.

3.1 — Détection de régime (HMM 4 états)

Un Hidden Markov Model gaussien à 4 états est entraîné offline (trimestriellement) sur l'historique complet des returns 2016 → today. À l'inférence quotidienne, on tourne **Viterbi** sur les 252 derniers returns pour identifier la séquence d'états la plus probable, et on émet `regime_id` (0–3) plus `P(regime)` pour les 4 états. Sortie : 4 lignes par jour dans la nouvelle table `pl_regime_state`.

RÉGIME	FRÉQUENCE HISTORIQUE	N TYPIQUE	STRATÉGIE
0 — Crash	0.3%	8	Hardcoded HEDGE (trop peu d'obs pour fit)
1 — Normal	76.6%	1980	Logistic complète, 11 poids
2 — Burst	4.4%	114	Logistic, ratio obs/params = 10 (juste OK)
3 — Bull	18.7%	484	Logistic complète

Pourquoi 4 états et pas 2 ou 3 ? Le critère BIC tranche : `delta_BIC = 934` en faveur de 4 états vs 2 (EXP-005). Les 4 états correspondent à des structures statistiques distinctes (mean return + volatilité + autocorrélation), pas à une étiquette discrétionnaire. Le label-switching potentiel du HMM est résolu en relabellisant les états par **moyenne de return ascendante** après chaque fit — déterministe et stable d'un retrain à l'autre.

Pourquoi pas un classifieur supervisé du régime ? Parce qu'il n'y a pas de label gold-standard du régime à apprendre. Le HMM est génératif et non-supervisé : il découvre les régimes à partir de la dynamique des returns, sans qu'on ait à les définir a priori. C'est exactement ce qu'on veut quand l'objectif est de capturer la structure du marché, pas une catégorisation humaine.

3.2 — Delta features (10 deltas sur 3 jours)

Les 14 indicateurs techniques classiques (EMA, MACD, RSI, Stoch, ATR, Bollinger, etc.) sont d'abord réduits à 10 (EXP-002 a montré que les 14 ont 6–7 dimensions indépendantes — le reste est redondant). Puis chaque indicateur passe par le pipeline canonique :

```
raw_value
  ↓ 5-day SMA (sauf close_pivot_ratio)
smoothed_value
  ↓ rolling 252j z-score, cap |Z| > 10
normalized_value
  ↓ delta sur 3 jours
delta_X[t] = norm[t] - norm[t-3]
```

Pourquoi des deltas et pas les niveaux ? EXP-010 a comparé directement les deux : sur la fenêtre post-rupture 2024 (où la stationnarité s'est cassée), les delta features ont fait **+6pp** de précision vs les niveaux. L'intuition : un niveau RSI z-scoré dépend de la moyenne 252j, qui peut elle-même dériver lentement avec le régime. Une variation sur 3 jours est par construction insensible à ce drift — elle mesure du changement, pas un état. Ce qui survit aux ruptures structurelles.

Les 10 indicateurs retenus (post EXP-002 / EXP-008) :

INDICATEUR	FORMULE	JUSTIFICATION R&D
ema26	EMA(close, 26)	Trend baseline (EXP-002)
macd	EMA12 – EMA26	Top 1 importance RF (EXP-008)
macd_signal	EMA9(macd)	Confirmation
stochastic_d_14	SMA3(stoch_k_14)	Rang 2 importance RF
rsi_14d	Wilder's smoothing	LEAD en Granger (EXP-028)
atr_14d	EMA(TR, 14)	Seul TE-significatif
bollinger_width	(BB_up – BB_low) / SMA20	LEAD en Granger
close_pivot_ratio	close / pivot	Bidirectionnel Granger
volume_oi_ratio	volume / oi	Liquidité (héritage V1)
daily_return	pct_change(close)	Top 3 importance RF

3.3 — Logistic régime-conditionnelle (Pass 1 + Pass 2)

Pour chaque régime $r \in \{\text{Normal}, \text{Burst}, \text{Bull}\}$, on entraîne une régression logistique L2 distincte qui prédit la probabilité que le close à J+1 ferme en baisse :

$$P(\text{down} \mid \text{features}, \text{regime}=r) = \text{sigmoid}(W_r \cdot X + b_r)$$
$$= 1 / (1 + \exp(-(W_r \cdot X + b_r)))$$

Le régime **Crash** (0.3% des jours, n=8) n'a pas assez d'observations pour fitter une logistique stable — on hardcode HEDGE pour ce régime, comportement défensif assumé.

Le pipeline tourne en deux passes successives :

- **Pass 1 — sans macro.** $X = [10 \text{ delta features techniques}]$. Donne `p_down_pass1`. Robuste car ne dépend pas du LLM.
- **Pass 2 — avec macro LLM.** $X = [10 \text{ delta features} + \text{sentiment} + \text{supply_demand} + \text{climate_risk}]$ (13 features). Les 3 macro features sortent du LLM nightly (`cc-daily-analysis`) et ne sont pas z-scorées — elles sont déjà bornées par construction du schema LLM (`[-1, +1]` ou `[0, 1]`). Donne `p_down_pass2` qui devient `p_down` final si la pass 2 réussit.

Le macro_lift est un signal d'audit. On stocke `macro_lift = p_down_pass2 - p_down_pass1` en DB. C'est exactement le coup de pouce (positif ou négatif) que la macro LLM apporte par-dessus le signal technique pur. En cas d'échec du LLM (timeout, output mal formé), on garde Pass 1 comme fallback automatique — le système ne plante jamais à cause d'une dépendance LLM.

Pourquoi L2 et pas L1 ou ElasticNet ? Avec 10–13 features et un signal univarié faible (`|p|=0.06` max), L1 risquerait de sparsifier trop — supprimer des features qui contribuent ensemble même si elles sont individuellement faibles. L2 contracte les poids sans en éliminer aucun, ce qui est le comportement souhaité quand on sait qu'on cherche une combinaison non-univariée. `C=0.1` (régularisation modérée) est le défaut EXP-009.

3.4 — Logique de décision (seuils par régime)

Une fois `p_down` calculée, la décision finale dépend de seuils **spécifiques au régime**, parce qu'un même `p_down=0.55` n'a pas la même valeur informationnelle en Normal qu'en Bull :

RÉGIME	OPEN_THRESHOLD	HEDGE_THRESHOLD	JUSTIFICATION
Normal	0.40	0.65	Conservateur (signal faible en Normal)
Burst	0.35	0.60	Plus agressif (signal plus fort en high-vol)
Bull	0.30	0.70	Asymétrique (biais structurel haussier)
Crash	—	—	Override = HEDGE quoi qu'il arrive

Ces valeurs sont indicatives — elles seront re-calibrées par sweep dans le training script (étape 6 de la stratégie d'entraînement, cf. § 4.2). La règle de décision en pseudocode :

```
def decide(p_down, regime_id, thresholds):
    open_th, hedge_th = thresholds[regime_id]
    if regime_id == 0:          # CRASH override
        return "HEDGE"
    if p_down >= hedge_th:
        return "HEDGE"
    if p_down <= open_th:
        return "OPEN"
    return "MONITOR"
```

Note : pas de position sizing dans le moteur. La sortie est `p_down + confidence_score + decision` .
Le sizing reste à la discrétion du LLM Call #2 (synthèse trading) et du trader humain — c'est cohérent avec le scope produit actuel.

Ce qu'on déploie concrètement

4.1 — Schéma DB (1 migration Alembic, idempotente)

ÉLÉMENT	QUOI
<code>pl_algorithm_version</code>	<code>INSERT name='regime', version='4.0.0', is_active=false, compute_enabled=true</code>
<code>pl_regime_state</code> (NEW table)	4 rows / jour / contrat : (<code>date</code> , <code>contract_id</code> , <code>regime_id</code> , <code>probability</code>) . Permet de stocker l'historique complet des probabilités HMM par régime — utile pour audit, monitoring du drift, et replay.
<code>pl_macro_features</code> (NEW table)	1 row / jour : <code>sentiment_score</code> , <code>supply_demand_balance</code> , <code>climate_risk_score</code> écrits par le LLM Call #1. Sépare clairement les inputs macro des autres signaux.
<code>pl_indicator_daily</code>	Champs ajoutés : <code>p_down</code> , <code>p_down_pass1</code> , <code>regime_id</code> , <code>regime_probability</code> , <code>macro_lift</code> . <code>confidence_score</code> et <code>decision</code> existent déjà.
<code>pl_logistic_model</code> (NEW table)	Stocke par version : URI GCS du joblib + SHA-256 + thresholds par régime + métadonnées de training (window, fold, métriques de validation).

4.2 — Code (nouveaux fichiers)

```

backend/
  alembic/versions/<hash>_add_regime_v4_tables.py      ← migration
  app/engine/regime/                                  ← détection régime +
logistic
  hmm.py          # HMM Viterbi quotidien, relabel by mean ascending
  delta_features.py # pipeline z-score 252j → delta 3j (10 features)
  logistic.py      # logistic régime-conditionnelle, Pass 1 + Pass 2
  decision.py      # decide(p_down, regime_id, thresholds)
  pipeline.py      # RegimePipeline (orchestrator)
app/models/
  regime_state.py      # PlRegimeState
  macro_features.py    # PlMacroFeatures
  logistic_model.py    # PlLogisticModel
scripts/train_logistic/                                ← training offline
trimestriel
  main.py + data_loader / hmm_fitter / logistic_fitter
           / threshold_calibrator / walk_forward_validator
           / artifact_writer
scripts/regime_finalize/                                ← nightly job
  main.py + hmm_loader / logistic_loader / db_writer
tests/engine/test_hmm_viterbi.py
tests/engine/test_delta_features.py
tests/engine/test_logistic_regime.py
tests/engine/test_decision_rules.py
tests/scripts/test_regime_finalize.py

```

Le code v3 (accuracy) n'est pas touché. L'engine `runner.py` aiguille vers la bonne stratégie selon `algorithm_name` ("legacy" , "accuracy" , "regime"). Les trois algos peuvent coexister en DB pendant les phases de validation et de shadow.

4.3 — Pipeline nightly (4 passes)

Le nightly intègre une nouvelle passe pour le calcul du régime + logistic. `cc-daily-analysis` est étendu pour écrire les 3 features macro dans `pl_macro_features` (en plus du `macroeco_bonus` v3) :

```

19:15 cc-compute-indicators   écrit les indicateurs techniques (utilisé par v3 + v4)
19:18 cc-regime-detect        ← NOUVEAU : HMM Viterbi → pl_regime_state
19:20 cc-daily-analysis       écrit macroeco_bonus (v3) + 3 macro features (v4)
19:25 cc-accuracy-finalize    v3 GBM gate (inchangé)
19:27 cc-regime-finalize      ← NOUVEAU : logistic Pass 1 + Pass 2 + decision
19:30 cc-compass-brief       lit la version active

```

Pourquoi `regime-detect` avant `daily-analysis` ? Le LLM Call #1 (analyse macro) reçoit le régime courant comme contexte dans son prompt — ça aide à produire un sentiment cohérent avec la dynamique de marché du moment. Le HMM tournant en 50 ms sur 252 returns, on a tout le temps de l'insérer entre `compute-indicators` et `daily-analysis`.

4.4 — Infra (2 nouveaux jobs + 2 nouveaux crons + 2 deps Python)

- `backend/pyproject.toml` : ajouter `hmmlearn ^0.3` (production, Viterbi quotidien). `scikit-learn` est déjà installé via v3.
- `.github/workflows/deploy.yml` : ajouter `cc-regime-detect` et `cc-regime-finalize` à la boucle Cloud Run (de 9 → 11 jobs). Réutilise `Dockerfile.jobs`.
- `infra/terraform/scheduler.tf` : 2 nouveaux crons (`18 19 * * 1-5` et `27 19 * * 1-5`).
- GCS bucket `cacao000-models` (déjà créé pour v3) : ajouter prefix `regime/` pour les artefacts joblib HMM + logistic.

4.5 — Estimation runtime

ÉTAPE	RUNTIME
Indicateurs + z-score + delta	~2 s
HMM Viterbi (online, 252 returns)	~50 ms
Logistic predict (par régime)	~5 ms
Total inférence quotidienne	< 100 ms
Training script offline (HMM + 3 logistcs + sweep)	~30 min

05 · VALIDATION

Validation & rollout

Contrairement à `accuracy v3.0.0` où le shadow mode démarrait directement, `regime v4.0.0` passe par une **phase de validation R&D bloquante** avant tout déploiement nightly. La raison : le risque d'overfitting est plus élevé (~72 paramètres vs 35 pour v3) et l'enjeu scientifique est lui-même incertain (l'hypothèse `delta ≥ +5pp` doit être prouvée, pas supposée).

PHASE	DURÉE	ACTION	CRITÈRE PASS
1. Validation walk-forward	1 sprint (offline)	5 folds expanding window (2016–2019 → 2020 ; ... ; 2016–2023 → 2024–2025) sur train. Bootstrap 5000 iter, stratified par régime.	Pre-registered (cf. § 6) : $\text{delta} \geq +5\text{pp}$, CI exclut zéro
2. Holdout strict	1 jour (run + analyse)	Test sur 374 jours strict holdout (2024-09-15 → 2026-04). Aucun tuning, aucun pre-look — on n'a touché à ces données qu'une fois.	$\text{delta}(\text{holdout}) \geq 0.5 \times \text{delta}(\text{train})$; HEDGE precision $\geq 75\%$
3. Shadow nightly	10 jours ouverts	v4.0.0 tourne en parallèle de v3.0.0, écrit ses propres rows. Dashboard et compass-brief restent sur v3.0.0.	Décisions cohérentes avec backtest holdout (drift < 5pp)
4. Cutover (conditionnel)	Day 11	Flip <code>is_active</code> de v3.0.0 vers v4.0.0 si phase 3 OK.	—
5. Steady-state	Continu	Champion/challenger : v4.0.0 reste actif tant que $\text{delta vs HEDGE} \geq 0\text{pp}$ sur fenêtre 60j roulante.	Sinon fallback Algo B

NOTE IMPORTANTE Si la phase 1 ou la phase 2 échoue, on **ne déploie pas**. C'est un commitment écrit à l'avance — pas négociable post-hoc, pas « bon allez on regarde quand même ». L'objectif est d'éviter le piège classique : laisser une intuition narrative pousser un déploiement quand les chiffres disent non.

Rollback

Identique à v3 — une transaction SQL :

```
BEGIN;
  UPDATE pl_algorithm_version SET is_active = true WHERE name='accuracy' AND
version='3.0.0';
  UPDATE pl_algorithm_version SET is_active = false WHERE name='regime' AND
version='4.0.0';
COMMIT;
```

Les jobs `cc-regime-detect` et `cc-regime-finalize` continuent à tourner pour audit, mais le dashboard et compass-brief reviennent à v3.0.0. Pour stopper les jobs :

```
gcloud scheduler jobs pause cc-regime-detect-trigger cc-regime-finalize-trigger .
```

Champion-challenger en steady-state

Une fois v4.0.0 actif, on monitore en continu son edge sur fenêtre roulante 60 jours :

- Si $\text{delta}(60j) \geq 0pp$ → v4 reste champion.
- Si $-2pp \leq \text{delta}(60j) < 0pp$ pendant 3 mois consécutifs → alerte refit (retrain trimestriel anticipé).
- Si $\text{delta}(60j) < -2pp$ pendant 3 mois → fallback automatique vers Algo B (challenger), v4 redevient challenger en attendant correctif.

Critères de succès chiffrés

6.1 — Pre-registered success criteria

Les critères ci-dessous sont **écrits avant** de tourner les expériences. C'est le commitment scientifique de la release : si ces seuils ne sont pas atteints, on ne déploie pas, point.

CRITÈRE PRIMARY (BLOQUANT)

Delta vs Always-HEDGE $\geq +5$ pp sur la concaténation walk-forward, **ET** CI 95% (bootstrap 5000 itérations stratifié par régime) exclut zéro, **ET** $\text{delta}(\text{holdout } 2024-09 \rightarrow 2026-04) \geq 0.5 \times \text{delta}(\text{train})$.

Critère SECONDARY. HEDGE precision $\geq 75\%$ sur holdout (vs base $\sim 50\%$ Always-HEDGE).
REJECTION. Si PRIMARY n'est pas atteint sur 2024–2026 → refus de déploiement et fallback automatique sur Algo B (EXP-033).

6.2 — Méthode walk-forward (5 folds expanding window)

Ordre temporel strict, pas de shuffle, pas de fuite future :

FOLD	TRAIN	TEST	SPÉCIAL
1	2016–2019	2020	Avant rupture
2	2016–2020	2021	Avant rupture
3	2016–2021	2022	Avant rupture
4	2016–2022	2023	Avant rupture
5	2016–2023	2024–2025	Inclut rupture 2024-01-30

Yearly breakdown obligatoire. Au moins 5 années sur 7 doivent avoir $\text{delta} > 0$. Rappel EXP-031 : sur des analyses passées, l'année 2024 (+27.1pp) tirait toute la performance moyenne — sans elle, le reste était autour de zéro. On veut éviter de reproduire ce piège, donc on regarde année par année et on exige une majorité positive.

6.3 — Holdout strict 2024-09 → 2026-04

374 jours qui n'ont **jamais** été utilisés en training, calibration de seuils, ni feature selection. Première et unique exposition lors de la phase 2 du rollout.

Règle : si `delta(holdout) < 0.5 × delta(train)` , c'est de l'overfitting et on refuse le déploiement. Cette règle protège du scénario où on a (involontairement) optimisé sur des signaux qui ne survivent pas hors-échantillon.

6.4 — Métriques principales

MÉTRIQUE	DÉFINITION	TARGET
Delta vs Always-HEDGE	<code>accuracy_algo - accuracy_hedge</code>	≥ +5 pp avec CI 95% excluant zéro
HEDGE precision	<code>P(down HEDGE signal)</code>	≥ 75% (vs base ~50%)
Coverage	<code>(n_OPEN + n_HEDGE) / n_total</code>	≥ 30%
Calibration	<code>binned_p_down vs actual_down_rate</code>	slope ≈ 1, intercept ≈ 0

Métriques secondaires monitorées : Brier score, log loss, confusion matrix par régime, stabilité de détection régime (transitions sensibles aux paramètres ?).

6.5 — Alertes monitoring continu (post-cutover)

MÉTRIQUE	PÉRIODE	SEUIL ALERTE
Delta vs HEDGE roulant	60 jours	< -2 pp pendant 3 mois → fallback Algo B
Distribution régimes	rolling 30 jours	Crash > 5% (anomalie) ou Normal < 50% (régime structurellement changé)
Macro lift médian	rolling 30 jours	<code> macro_lift > 0.10</code> ou variance > 0.05 (LLM hallucinations ?)
HMM convergence	chaque retrain trimestriel	Échec convergence ou label-switching détecté → bloquer mise à jour des poids

Cadence retrain : **trimestrielle** par défaut (cron manuel `poetry run regime-train`), **anticipée** si l'alerte 1 se déclenche.

6.6 — Tests d'acceptance pré-deploy (CI)

À ajouter en `pytest -m regime_acceptance` — bloquent le merge :

#	TEST	EXPECTED
1	HMM Viterbi reproduction (seed=42)	Séquence régimes identique au notebook EXP-005
2	HMM relabel by ascending mean	<code>regime_id=0</code> (Crash) a la moyenne return la plus négative
3	Delta features causal (no look-ahead)	<code>delta_X[t]</code> n'utilise que <code>X[t]</code> et <code>X[t-3]</code>
4	Logistic predict per régime	3 modèles distincts (Normal, Burst, Bull) ; régime 0 → HEDGE override
5	Pass 1 fallback si LLM échoue	<code>p_down = p_down_pass1</code> ; <code>macro_lift = NULL</code>
6	Pre-registered criteria sur holdout	$\text{delta} \geq +5$ pp ET CI exclut zéro (sinon rejet déploiement)

07 · LIMITATIONS

Limitations honnêtes

À présenter avant approbation. Aucune ne disqualifie la release individuellement, mais elles cadrent les attentes et orientent le monitoring continu.

LIMITATION 1 — RISQUE D'OVERFITTING (~72 PARAMÈTRES)

HMM (24) + 3 logistics (33) + extension macro (9) + thresholds (6) $\approx$ 72 paramètres trainables. Avec `n_eff = 1547` observations, on a un ratio obs/params de 21:1 — juste au-dessus du minimum de 20:1 généralement admis. **C'est précisément pour ça qu'on a un holdout strict de 374 jours non-touchés.** Si le delta sur holdout chute à moins de 50% du delta sur train, on rejette la release. Mitigation supplémentaire : régularisation L2 (C=0.1) sur toutes les logistiques.

LIMITATION 2 — NON-STATIONNARITÉ POST-2024 (ALERTE FORTE)

EXP-031 a documenté un signal directionnel **+27.1pp en 2024** contre **-1pp sur 2025-2026**. C'est une dispersion temporelle énorme qui suggère que la rupture 2024-01-30 a changé la dynamique de marché. Le modèle peut très bien fitter brillamment le pré-2024 et ne pas généraliser à l'après. C'est exactement le risque que le critère « $\text{delta}(\text{holdout}) \geq 0.5 \times \text{delta}(\text{train})$ » est conçu pour attraper. **Probabilité estimée d'échec sur ce critère : moyenne à élevée.**

LIMITATION 3 — RÉGIME BURST SOUS-REPRÉSENTÉ (N=114)

Le régime Burst représente 4.4% des observations historiques, soit ~114 points. La logistic Burst a 11 paramètres $\rightarrow$ ratio obs/params = 10:1, soit la moitié du minimum recommandé. Cela rend les poids du régime Burst peu fiables individuellement. Mitigation : si convergence échoue ou si les poids divergent fortement entre folds, fallback sur les poids du régime Normal (politique conservatrice).

LIMITATION 4 — MACRO FEATURES LLM = BRUIT POTENTIEL

Les 3 macro features (sentiment, supply/demand, climate risk) viennent d'un GPT-4 prompt nightly. Si le LLM hallucine de manière biaisée (ex. sentiment systématiquement positif sur 30 jours), Pass 2 dégrade Pass 1. **Mitigation** : (i) Pass 1 reste calculé et stocké en DB, on peut switcher dessus en config sans redéploiement ; (ii) monitoring continu de `macro_lift` avec alerte si dérive (cf. § 6.5) ; (iii) si la macro tombe, on tombe gracieusement sur Pass 1, jamais en MONITOR par défaut.

LIMITATION 5 — PÉRIMÈTRE DE SIGNAL VOLONTAIREMENT LIMITÉ

Pas de term structure (gap P0 du Deep Dive), pas de FX (GBP/USD), pas de cross-commodity (sucre, café qui corrélaient souvent), pas de gate vol_ratio. Ces choix sont assumés pour pouvoir

comparer rigoureusement vs Algo B (qui partage le même périmètre). Une release v5 pourra enrichir, mais l'objectif ici est de prouver le paradigme régime-conditionnel, pas de maximiser tout le signal disponible.

LIMITATION 6 — PAS DE GATE VOL_RATIO

On trade tous les jours (par design). C'est plus pur scientifiquement (la performance est entièrement attribuable au modèle, pas à un filtre exogène) mais ça veut dire qu'en marchés ultra-calmes ($\text{vol} < 0.8$ sustained plusieurs mois), le modèle prédit dans le bruit. Mitigation : le critère « coverage $\geq 30\%$ » force au moins 30% de signaux actifs ; si on tombe sous, c'est un signe que les seuils par régime sont mal calibrés.

Annexes

A. Comptage des paramètres trainables

COMPOSANT	PARAMS	NOTES
HMM 4 états	~24	means(4) + covars(4) + transmat(4×4) + startprob(4)
Logistic per régime (3 actifs)	11 × 3 = 33	10 weights + bias par régime (Crash hardcoded)
Pass 2 macro extension	3 × 3 = 9	3 macro weights par régime actif
Thresholds	2 × 3 = 6	open_threshold, hedge_threshold par régime
Total trainable	~72	n_eff/params = 1547/72 = 21:1

B. Comparatif des approches considérées

APPROCHE	PLAFOND PRÉCISION	CONDITIONNEL RÉGIME ?	GATE MACRO ?	STATUT
legacy v1.0.1	~30%	Non	Implicite (poids macro)	Production passée
accuracy v3.0.0	~60%	Non	GBM gate	Production actuelle
regime v4.0.0 (cette release)	≥ +5pp vs HEDGE (à valider)	Oui (HMM 4 états)	Macro lift Pass 2	Validation R&D
Algo B (EXP-033, fallback)	~52% (plafond directionnel assumé)	Non	Non	Plan B documenté

C. Coût opérationnel (ordre de grandeur)

- 2 nouveaux Cloud Run Jobs nightly (cc-regime-detect ~50ms, cc-regime-finalize ~3 min, 1 GiB RAM) : négligeable (< 1 €/mois Cloud Run).
- 1 prefix GCS additionnel cacaooo-models/regime/ (~200 KB par retrain trimestriel : HMM joblib + 3 logistics joblib + thresholds JSON) : négligeable.

- 0 nouveau service / API endpoint / DB instance. 1 dépendance Python supplémentaire (`hmmlearn` , ~5 MB).

D. Output files du training script

FICHIER	CONTENU
<code>output/regime_v4/walk_forward_results.csv</code>	Daily predictions vs actual sur les 5 folds
<code>output/regime_v4/yearly_breakdown.csv</code>	Performance année par année (critère 5/7 années > 0)
<code>output/regime_v4/calibration_curves.png</code>	P(down) prédite vs réalisée par bin
<code>output/regime_v4/holdout_validation.txt</code>	Résultats sur 2024-09 → 2026-04 (374 jours)
<code>output/regime_v4/v4_params.json</code>	Poids logistic + HMM + thresholds calibrés

E. Références R&D

EXP	TITRE	FINDING APPLIQUÉ
<code>EXP-002</code>	Indicator dimensionality	Set réduit à 10 (vs 14, 6–7 dim indep)
<code>EXP-005</code>	Formal regime detection	4 régimes HMM, BIC delta=934, rupture 2024-01-30
<code>EXP-007</code>	Skill benchmark	Power-law a NO SKILL → besoin de remplacement
<code>EXP-008</code>	Feature importance	Top 5 RF + rank corr Normal/Bull = 0.024
<code>EXP-009</code>	Decision functions	Régime ensemble +3.1pp meilleur
<code>EXP-010</code>	Short-window features	Delta features +6pp vs niveaux post-rupture
<code>EXP-027</code>	Normalization	Z-score 252j corrige look-ahead
<code>EXP-029</code>	Minimum viable signal	⚠ 2 features > 10 features (à documenter)
<code>EXP-031</code>	Signal diagnostic	⚠ Non-stationnarité 2024 vs 2025–26

Documents de référence : plan original `docs/plans/2026-04-01-compass-v2-logistic-engine.md` ; comparatif `docs/COMPASS_V2_VS_EXP033_SYNTHESIS.md` ; rapport complet `docs/R&D_CACAO_FINAL_REPORT.md` .



COMMODITIES COMPASS · REGIME V4.0.0 · MAI 2026 · CONFIDENTIEL