



TIERED V6.0.0

DEPLOYMENT PRESENTATION

TIERED RISK SYSTEM · HMM RÉGIME · GARCH VOL · LOGISTIC GATÉE

AUDIENCE

ENG COMMODITIES COMPASS

STATUT

R&D VALIDÉ · BUILD INFRA

MAI 2026

SOMMAIRE

Table des matières

01	TL;DR	p. 03
02	Pourquoi cette release ?	p. 05
03	Comment ça marche, pédagogiquement	p. 07
04	Ce qu'on déploie concrètement	p. 12
05	Build & rollout	p. 16
06	Critères de succès chiffrés	p. 19
07	Limitations honnêtes	p. 23
08	Annexes	p. 25

AUDIENCE Équipe ingénierie commodities-compass.

OBJET Présenter `tiered v6.0.0` — système en 3 tiers de confiance qui prédit ce qui est prédictable (régime, volatilité, niveau de risque) à haute confiance, et n'émet de signal directionnel que sous `gate vol_ratio`. Audience : engineering pour valider le scope du chantier infra.

COMPANION DOCS Design original `docs/EXP033_SYSTEM_DESIGN.md` ; synthèse `docs/COMPASS_V2_VS_EXP033_SYNTHESIS.md` ; rapport R&D `docs/R&D_CACAO_FINAL_REPORT.md` .

STATUT Composantes individuellement validées (HMM, GARCH, gate, logistic) ; assemblage 3 tiers à construire ; **chantier infra significatif** (cf. § 4).

01 · SYNTHÈSE

TL;DR

`tiered v6.0.0` change radicalement de stratégie : **au lieu de chercher à prédire la direction (impossible > 52% sur cocoa daily, prouvé par 32 expériences R&D), on prédit ce qui EST prédictible** — le régime de marché, la volatilité du lendemain, le niveau de risque global — et on n'émet un signal directionnel que dans les conditions de marché où ce signal s'est avéré fiable. C'est un système qui dit honnêtement « je ne sais pas » 60–70 % du temps, et qui parle quand il a quelque chose à dire.

L'architecture s'organise en **3 tiers de confiance**, du plus certain au plus incertain :

1. **Tier 1 — High confidence.** Trois sorties que la R&D a prouvées prédictibles avec haute fiabilité : (i) le **régime de marché** via HMM 4 états avec persistance Normal à 97.6% ; (ii) la **volatilité du lendemain** via GARCH(1,1) avec persistance 0.97 et résidus ARCH éliminés ($p=0.73$) ; (iii) un **niveau de risque composite** (LOW / ELEVATED / HIGH / CRISIS) calculé déterministiquement à partir des deux premiers. Toujours produit, indépendamment du gate.
2. **Tier 2 — Medium confidence (gaté).** Un signal directionnel **PROTECT** / **CAUTIOUS** / **MONITOR** / **TRADE** émis **uniquement si** `vol_ratio ≥ 1.10` (sinon MONITOR par défaut). Sous le gate, une logistique L2 par régime (2 features : `delta_macd_3d` , `delta_atr_3d`) sort une probabilité `p_down` . La R&D (EXP-031) a montré +9.1 pp d'edge sous gate, IC 95% = [+3.3, +14.8].
3. **Tier 3 — Informational.** Valeurs brutes (MACD, RSI, ATR, Bollinger width), **sizing de position calculé en inverse vol** à partir du Tier 1 (`position = target_risk / vol_forecast`), et trailing accuracy 30 jours pour aider le trader à calibrer sa propre confiance dans le système.

Le nom `tiered v6.0.0` reflète cette stratification. Côté livraison, c'est l'algo des quatre qui demande le plus gros chantier infra : **2 nouvelles tables DB** (`pl_regime_state` , `pl_vol_forecast`), **2 nouvelles dépendances Python** (`hmmlearn` , `arch` pour le GARCH), **3 cadences de retrain différentes** (HMM trimestriel, GARCH mensuel, logistique trimestrielle), et un job nightly multi-passes qui orchestre les 3 tiers. C'est aussi celui dont la sortie produit est la plus riche : 17 champs en DB par jour, vs 5–8 pour les approches classiques.

POURQUOI C'EST INTÉRESSANT

Le système est **valuable même si Tier 2 échoue**. Tier 1 (régime + vol forecast) sert directement au trader pour : sizing de position via inverse vol, alertes de transition de régime, niveau de risque global (LOW → CRISIS). Ces outputs sont indépendants de la capacité à prédire la direction.

Le pari. Si la R&D walk-forward confirme que le gate `vol_ratio ≥ 1.10` tient (+9.1 pp avec IC excluant zéro empiriquement), `tiered v6.0.0` a le potentiel de devenir le système de référence. Si Tier 2 s'effondre mais Tier 1 reste calibré, on conserve le système pour son apport en gestion

de risque — et on sait qu'il faut investir en nouvelles données (term structure, COT positioning) pour aller plus loin.

TIERS

3

High / Medium / Info

PARAMS TRAINABLES

~36

ratio obs/params 43:1

EDGE SOUS GATE

+9.1 pp

IC 95% [+3.3, +14.8]

Pourquoi cette release ?

Le constat de départ : le plafond directionnel

32 expériences R&D conduites sur l'historique cocoa 2016–2026 convergent vers la même conclusion : **la prédiction directionnelle quotidienne plafonne autour de 52 % de précision**. Aucun feature seul ne dépasse $|p|=0.06$ en corrélation univariée avec le retour de J+1, et les combinaisons multi-features peinent à passer 53–54 % sans tomber dans l'overfitting. C'est un plafond d'information, pas un défaut algorithmique.

Face à ce constat, deux philosophies s'opposent :

- **Continuer à pousser le directionnel** avec plus de features, plus de complexité, des modèles régime-conditionnels — espérer gagner 2–3 pp marginaux à chaque itération.
- **Renoncer à prédire la direction quand c'est impossible**, et capitaliser sur ce qui EST prédictible. C'est cette voie qu'instancie `tiered v6.0.0`.

Ce qui EST prédictible (et ce qui ne l'est pas)

Toute la R&D peut se résumer en une matrice : pour chaque grandeur d'intérêt, quelle est la qualité du signal sur 10 ans de données ?

GRANDEUR	QUALITÉ DU SIGNAL	SOURCE R&D	VERDICT
Direction daily	~52 %	EXP-007, EXP-029, EXP-031	Plafond structurel
Régime de marché (HMM)	97.6 %	EXP-005	Très prédictible
Volatilité tomorrow (GARCH)	persistance 0.97	EXP-027	Très prédictible
Direction sous gate vol_ratio ≥ 1.10	+9.1 pp	EXP-031	Prédictible conditionnellement
Direction hors gate	~50 %	EXP-031	Bruit pur

L'asymétrie est frappante. Régime et volatilité sont **fortement persistants** (97 %), donc prédictibles avec une précision élevée par des modèles standards (HMM, GARCH). La direction quotidienne, elle, est essentiellement non-prédictible — sauf dans les fenêtres où la volatilité expand (gate

`vol_ratio ≥ 1.10`), qui représentent ~28 % du temps et où le signal monte à **+9.1 pp** avec IC excluant zéro.

L'idée centrale de `tiered v6.0.0` est de **séparer ces deux types de prédiction** dans la même architecture : un Tier 1 « toujours actif » qui produit régime + vol + risque (utilisable même seul pour le sizing et les alertes), et un Tier 2 « conditionnel » qui ne s'active que sous le gate.

Honnêteté épistémique : dire MONITOR plutôt qu'inventer

Une conséquence directe : **le système dit MONITOR (« je ne sais pas ») 60–70 % du temps**. C'est un trade-off délibéré. Plutôt qu'émettre un faux signal directionnel quand l'algorithme n'a pas d'edge mesurable, on s'abstient explicitement. Le Tier 1 reste informatif (régime, vol, niveau de risque continuent de s'afficher), mais aucune recommandation directionnelle n'est faite.

Pour le trader humain, cela change la nature de l'outil : ce n'est plus un système qui « parle tous les jours » mais un système qui parle quand il a quelque chose à dire. La barre de qualité par signal émis monte mécaniquement — moins de bruit dans le brief audio, plus de poids quand un signal sort.

Pourquoi maintenant

Toutes les composantes individuelles sont validées par la R&D :

COMPOSANTE	VALIDATION	RÉFÉRENCE
HMM 4 états (BIC delta=934 vs 2 états)	Validé	EXP-005
GARCH(1,1) (résidus ARCH éliminés, p=0.73)	Validé	EXP-027
2 features macd+atr (+6.9 pp, CI exclut zéro)	Validé	EXP-029
Gate <code>vol_ratio ≥ 1.10</code> (+9.1 pp, CI exclut zéro)	Validé	EXP-031
Delta features 3j (+6 pp post-rupture)	Validé	EXP-010
Adaptive regime signal (signal non-stationnaire post-2024)	Validé	EXP-032

Cette release consolide ces 6 briques en une architecture intégrée. Le travail R&D pur est terminé ; ce qui reste est un **chantier d'engineering** : porter ces composantes en code production, créer les tables DB, orchestrer les 3 cadences de retrain, et valider l'intégration end-to-end. C'est non-trivial, et c'est précisément le sujet de cette release.

03 · ARCHITECTURE

Comment ça marche, pédagogiquement

Le pipeline est composé de trois tiers indépendants exécutés en série chaque nuit. Tier 1 produit toujours ses sorties (régime, vol, risque) parce que les composantes sont fiables > 95 %. Tier 2 est conditionnel : il ne s'active que si le gate `vol_ratio ≥ 1.10` est passé, ce qui se produit ~28 % du temps. Tier 3 est purement informatif et calculé déterministiquement à partir des outputs précédents.

3.1 — Tier 1a : Détection de régime (HMM 4 états)

Un Hidden Markov Model gaussien à 4 états est entraîné offline (trimestriel) sur l'historique complet des returns. À l'inférence quotidienne, on tourne un **forward filter** (pas Viterbi) sur les 252 derniers returns, ce qui donne la distribution postérieure du régime à t et permet de calculer la **persistance** (probabilité de rester dans le même régime demain) directement depuis la matrice de transition.

RÉGIME	N HISTORIQUE	VOL ANNUALISÉE	MEAN RETURN / JOUR	PERSISTANCE
0 — Crash	8	233 %	-1.9 %	63.7 %
1 — Normal	1980	21 %	+0.02 %	97.6 %
2 — Burst	114	59 %	+0.3 %	94.5 %
3 — Bull	484	53 %	+0.1 %	47.9 %

Pourquoi forward filter et pas Viterbi ? Viterbi donne la séquence d'états la plus probable pour toute la fenêtre passée, ce qui est utile en analyse rétrospective mais surdimensionné pour l'inférence live. Le forward filter donne uniquement la distribution postérieure du jour courant, ce qui est exactement ce qu'il faut pour la production et coûte 10× moins en calcul. Le label-switching potentiel est résolu en relabellisant les états par moyenne de return ascendante — déterministe et stable d'un retrain à l'autre.

3.2 — Tier 1b : Volatility forecast (GARCH 1,1)

Un modèle GARCH(1,1) avec distribution t-Student est fitté offline (mensuel) sur les returns récents. Le modèle prédit la variance conditionnelle du lendemain à partir du return d'aujourd'hui et de la variance d'hier :

$$\sigma^2_t = \omega + \alpha \cdot r^2_{t-1} + \beta \cdot \sigma^2_{t-1}$$

Paramètres estimés (full history) :

$\omega = 0.0835$ (constant)
 $\alpha = 0.0592$ (ARCH coefficient)
 $\beta = 0.9137$ (GARCH coefficient)
 Persistence ($\alpha + \beta$) = 0.9729

L'inférence quotidienne est triviale (3 multiplications, 2 additions) :

```

σ²_today      = ω + α · (return_today × 100)² + β · σ²_yesterday
σ²_tomorrow  = ω + (α + β) · σ²_today
vol_tomorrow_ann = sqrt(σ²_tomorrow × 252) / 100
  
```

L'IC 95 % empirique est $[\text{vol} \times 0.7, \text{vol} \times 1.3]$, calibrée sur les fenêtres roll-forward.

Pourquoi GARCH(1,1) et pas un modèle plus sophistiqué (GARCH-M, FIGARCH, vol stochastique) ?

Parce qu'EXP-027 a montré que GARCH(1,1) capture déjà **la quasi-totalité** de la dynamique : les résidus standardisés ne montrent plus d'effet ARCH (test Ljung-Box, $p=0.73$), et la persistance estimée 0.97 est cohérente avec la littérature. Aller plus complexe (Heston, etc.) demanderait 10× plus de paramètres pour un gain marginal sur cocoa daily.

3.3 — Tier 1c : Risk level compound score

À partir de Tier 1a et 1b, un score composite déterministe attribue un niveau de risque global au jour courant :

```

score = 0
# Régime
if regime == 0 (Crash):      score += 3
elif regime in {2, 3}:      score += 1  # Burst ou Bull
# Percentile vol annualisée vs 252j historique
if vol_pctile > 0.9:        score += 2
elif vol_pctile > 0.7:      score += 1
# Expansion vol
if vol_ratio > 1.3:         score += 2
elif vol_ratio > 1.1:       score += 1

# Mapping
if score >= 4: return "CRISIS"
if score >= 3: return "HIGH"
if score >= 2: return "ELEVATED"
return "LOW"
  
```

C'est délibérément simple : pas de ML, pas de calibration apprise — uniquement des seuils tirés de l'analyse historique. Le but n'est pas la précision optimale, c'est de fournir un **indicateur lisible et**

reproductible que le trader peut interpréter à coup d'œil. L'output sert aussi d'override : si le risk level est `CRISIS`, l'action Tier 2 est forcée à `PROTECT` quoi qu'il arrive.

3.4 — Tier 2 : Logistic conditionnelle (gatée par vol_ratio)

Tier 2 est le seul tier directionnel — et il est **gaté**. Avant tout calcul logistic, on vérifie le gate :

```
if vol_ratio < 1.10:
    return ("MONITOR", confidence=0)  # Pas de signal directionnel
```

Le seuil **1.10** a été calibré par sweep walk-forward (EXP-031) — c'est le sweet spot où l'edge sur Always-HEDGE atteint **+9.1 pp avec IC 95 % = [+3.3, +14.8]**, soit largement strictement positif. Hors gate, l'edge tombe à zéro (ou pire) — le modèle n'a pas de signal exploitable dans les marchés calmes.

Sous gate actif, on applique une logistique L2 **par régime** sur 2 features uniquement :

```
features = [delta_macd_3d, delta_atr_3d]  # 2 deltas sur 3 jours

P(down | regime=r) = sigmoid(w_r1 * delta_macd_3d
                             + w_r2 * delta_atr_3d
                             + b_r)

Régimes actifs (Normal / Burst / Bull) → 3 logistiques distinctes.
Régime Crash → P(down) = 1.0 hardcodé → PROTECT.
```

Pourquoi 2 features seulement ? EXP-029 a comparé 162 configurations (1 à 13 features) sur le même problème. Le sweet spot est `macd + atr` avec **+6.9 pp, IC=[+1.5, +12.2]** — qui bat les configurations à 5 ou 10 features. Avec un signal univarié faible, ajouter des features ajoute du bruit et dégrade l'IC. Less is more, prouvé empiriquement.

Pourquoi par régime ? Parce que la corrélation des feature importances entre régimes est faible (rank corr Normal/Bull = 0.024). En pratique : un MACD positif n'a pas le même sens dans un Bull que dans un Normal. Une logistique unique apprendrait au mieux la moyenne pondérée des deux comportements ; trois logistiques distinctes capturent chaque régime correctement.

DÉCISION FINALE TIER 2

À partir de la probabilité `p_down` sortie de la logistique, on map à 4 catégories selon la confiance et le signe :

CONDITION	ACTION	LECTURE
$ p_{\text{down}} - 0.5 \times 2 < 0.30$	MONITOR	Signal trop ambigu — pas d'action
$p_{\text{down}} > 0.65$	PROTECT	Signal baissier fort — couvrir
$p_{\text{down}} < 0.35$	TRADE	Signal haussier fort — exposer
Sinon (entre 0.35 et 0.65 avec confiance ≥ 0.30)	CAUTIOUS	Signal modéré — taille réduite

Le mapping est **symétrique autour de 0.5** par design — pas de biais structurel vers HEDGE ou OPEN. La R&D ne révélant pas d'asymétrie significative dans la loi du return conditionnel à p_{down} élevée vs basse, on garde le système symétrique.

3.5 — Tier 3 : Informational (sizing + audit)

Tier 3 ne produit pas de décision propre — il enrichit la sortie avec des éléments contextuels utiles au trader humain :

- **Position sizing inverse vol** — calculé à partir du Tier 1b. $\text{position} = \text{target_daily_risk} / (\text{vol_forecast} / \text{sqrt}(252))$. Exemple : pour un objectif 1 %/jour avec vol_forecast 35 % annualisée, le multiplicateur est 0.45×
- **Indicateurs bruts** — MACD, RSI, ATR, Bollinger width pour que le trader puisse vérifier visuellement la cohérence du signal Tier 2 si présent.
- **Trailing 30-day accuracy** — quand le système a parlé sur les 30 derniers jours, à quel taux a-t-il eu raison ? Permet au trader de calibrer dynamiquement sa propre confiance dans le système.

3.6 — Pipeline nightly orchestré

Les 3 tiers sont exécutés séquentiellement, avec persistance DB après chaque étape pour permettre l'audit et le replay indépendamment :

```
19:15 cc-compute-indicators      indicateurs techniques bruts (existant)
19:18 cc-tiered-tier1-regime     - NOUVEAU : HMM forward filter
                                écrit pl_regime_state (4 rows)
19:19 cc-tiered-tier1-vol        - NOUVEAU : GARCH update + forecast
                                écrit pl_vol_forecast (1 row)
19:20 cc-tiered-tier1-risk       - NOUVEAU : compound risk score
                                écrit pl_indicator_daily.risk_level
19:22 cc-tiered-tier2-direction  - NOUVEAU : gate check + logistic
                                écrit pl_indicator_daily.action + p_down
19:23 cc-tiered-tier3-info       - NOUVEAU : sizing + trailing accuracy
                                écrit champs informational
19:30 cc-compass-brief          lit la version active (existant)
```

Six jobs au total. Chacun est **idempotent** (rejouable sur le même jour sans effet de bord), petit (~50 lignes Python), et **indépendant des autres** en cas de crash : si Tier 1b plante, Tier 1a et 1c continuent ; Tier 2 dégrade gracieusement en MONITOR. Cette granularité a un coût opérationnel (6 jobs à monitorer) mais permet le debugging chirurgical et la reprise par étape.

Ce qu'on déploie concrètement

C'est la section critique de cette release : la R&D est faite, mais le chantier infra reste lourd.

Estimation : 2 à 3 sprints engineering pour un build complet et testé. Voici le détail.

4.1 — Schéma DB (1 migration Alembic, 4 tables touchées)

ÉLÉMENT	QUOI
pl_algorithm_version	INSERT name='tiered', version='6.0.0', is_active=false, compute_enabled=true
pl_regime_state (NEW table)	4 rows / jour / contrat : (date, contract_id, regime_id, probability) . Stocke la distribution complète des 4 régimes HMM. Permet l'audit du forward filter et l'analyse rétrospective des transitions.
pl_vol_forecast (NEW table)	1 row / jour / contrat : (date, contract_id, vol_forecast_ann, vol_realized_ann_20d, garch_omega, garch_alpha, garch_beta, fit_date) . Stocke le forecast GARCH et les paramètres utilisés (pour audit du retrain mensuel).
pl_indicator_daily	17 nouveaux champs : regime_id, regime_name, regime_probability, regime_persistence_1d, regime_change_5d, vol_forecast_ann, vol_forecast_ci_lo, vol_forecast_ci_hi, risk_level, risk_score, gate_active, vol_ratio, p_down, tier2_confidence, action, atr_high, position_sizing_1pct . C'est l'extension la plus large à ce jour.
pl_logistic_model (extension)	Schéma existant suffit. Stocke par version + par régime : URI GCS du joblib + SHA-256 + 2 weights + bias + métadonnées (window, fold metrics).
pl_garch_model (NEW table)	Stocke les paramètres GARCH par fit mensuel : (fit_date, omega, alpha, beta, persistence, residual_arch_pvalue, n_obs) . Petit (12 rows / an) mais critique pour l'audit.

4.2 — Code (nouveaux fichiers)

```

backend/
  alembic/versions/<hash>_add_tiered_v6_tables.py          ← migration
  app/engine/tiered/                                       ← logique algo
    tier1_regime.py      # HMM forward filter (NOT Viterbi)
    tier1_vol.py         # GARCH(1,1) update + 1-step forecast
    tier1_risk.py        # compound risk score (deterministic)
    tier2_gate.py        # vol_ratio gate check
    tier2_logistic.py    # 3 régime-conditional logistics
    tier2_decision.py    # decide(p_down, gate_active, regime, risk)
    tier3_info.py        # position sizing + trailing accuracy
    pipeline.py         # TieredPipeline (orchestrator des 3 tiers)
  app/models/
    regime_state.py     # PlRegimeState
    vol_forecast.py     # PlVolForecast
    garch_model.py      # PlGarchModel
    logistic_model.py   # PlLogisticModel (réutilisé)
  scripts/train_tiered/                                ← training offline
    train_hmm.py        # HMM (trimestriel) – réutilise pattern EXP-005
    train_garch.py      # GARCH (mensuel) – réutilise pattern EXP-027
    train_logistic.py   # 3 logistics gatées (trimestriel) – pattern EXP-029
    walk_forward.py     # validation 5 folds + bootstrap CI
    artifact_writer.py
  scripts/tiered_finalize/                              ← nightly jobs (6 sub-
modules)
    tier1_regime_main.py
    tier1_vol_main.py
    tier1_risk_main.py
    tier2_direction_main.py
    tier3_info_main.py
    common/            # loaders, db writers
  tests/engine/test_tiered_*.py                          ← une suite par tier
  tests/scripts/test_tiered_finalize.py

```

Estimation : ~1500 lignes Python (incluant les tests), ~3000 lignes si on compte les migrations Alembic et la doc inline. C'est le plus gros build des 4 algos en termes de surface de code.

4.3 — Pipeline nightly (6 nouveaux jobs Cloud Run)

Là où les autres algos ont 1 ou 2 nouveaux jobs, `tiered v6` en demande 6. Chaque tier est un job Cloud Run séparé pour permettre la dégradation gracieuse :

JOB	CRON	RUNTIME	FONCTION
cc-tiered-tier1-regime	18 19 * * 1-5	~50 ms	HMM forward filter → pl_regime_state
cc-tiered-tier1-vol	19 19 * * 1-5	~10 ms	GARCH update → pl_vol_forecast
cc-tiered-tier1-risk	20 19 * * 1-5	< 1 ms	Compound risk score → pl_indicator_daily
cc-tiered-tier2-direction	22 19 * * 1-5	~5 ms	Gate + logistic → action + p_down
cc-tiered-tier3-info	23 19 * * 1-5	~5 ms	Sizing + trailing accuracy
Total inférence quotidienne		< 100 ms	

Plus 2 crons mensuels / trimestriels offline pour le retrain :

```
0 4 1 * * cc-tiered-train-garch # 1er du mois, 04:00 UTC
0 4 1 1,4,7,10 * cc-tiered-train-hmm-logistic # Trimestriel
```

4.4 — Dépendances Python

Deux nouvelles dépendances, l'une commune au projet (`hmmlearn`), l'autre spécifique à cette release (`arch`) :

- `hmmlearn ^0.3.0` — HMM Viterbi + forward filter. Ajout au `pyproject.toml` production. ~5 MB packagé.
- `arch ^7.x` — bibliothèque GARCH référence en Python (Kevin Sheppard). Bien maintenue, dépendance de `scipy` uniquement. ~3 MB packagé. Nouvelle dépendance critique : à valider en sécurité supply-chain et licensing.
- `scikit-learn` et `numpy` / `pandas` sont déjà présents.

4.5 — Infrastructure additionnelle

- `.github/workflows/deploy.yml` : ajouter 5 jobs Cloud Run + 2 jobs de training (passe potentiellement de 8 à 15 jobs déployés). Réutilise `Dockerfile.jobs`.
- `infra/terraform/scheduler.tf` : 5 nouveaux crons nightly + 2 crons offline.

- GCS bucket `cacao000-models` : nouveau prefix `tiered/` avec 3 sous-prefix : `hmm/` , `garch/` , `logistic/` . Chaque retrain produit ~50 KB de joblib. Coût négligeable mais structure à mettre en place.
- **Monitoring GCP** : 6 nouveaux dashboards (un par job nightly) + 4 alertes (calibration regime, calibration GARCH, edge Tier 2, distribution actions). Plus de surface qu'un algo simple.

4.6 — Estimation de l'effort engineering

LOT	ESTIMATION	NOTES
Migration Alembic + 4 nouvelles tables	~1 jour	Standard, low-risk
Tier 1a : HMM module (réutilise EXP-005)	~3 jours	Forward filter à coder, tests calibration
Tier 1b : GARCH module (nouveau)	~3 jours	Apprentissage <code>arch</code> , tests calibration Mincer-Zarnowitz
Tier 1c : Risk score (déterministe)	~1 jour	Trivial, mais tests exhaustifs
Tier 2 : Gate + 3 logistics + decision	~3 jours	Le plus délicat — fallbacks, edge cases
Tier 3 : Sizing + trailing accuracy	~1 jour	Simple si Tier 1b solide
Training scripts (HMM + GARCH + logistic)	~4 jours	3 cadences différentes à orchestrer
Walk-forward complet + bootstrap CI	~2 jours	Réutilise pattern EXP-031
6 jobs Cloud Run + cron + Terraform	~3 jours	Nouveau pattern multi-jobs
Tests engine + intégration	~3 jours	Une suite par tier
Dashboards GCP + alertes	~2 jours	6 panels, 4 alert policies
Total	~26 jours	≈ 2-3 sprints engineering, 1 personne dédiée

05 · MISE EN PRODUCTION

Build & rollout

Vu l'ampleur du chantier infra, le rollout est **scindé en deux grandes phases** : une phase BUILD (engineering pur, 2-3 sprints) qui matérialise l'architecture, puis une phase VALIDATION + DEPLOY classique avec walk-forward, holdout, shadow et cutover.

Phase BUILD (sprints 1-3)

SPRINT	LIVRABLE	SORTIE DE PHASE
Sprint 1	Migration DB (4 tables) + Tier 1a (HMM) + Tier 1b (GARCH) + tests calibration unitaires	Tier 1 fonctionnel sur historique, persistance régime calibrée à 97.6 % $\pm$ 0.05
Sprint 2	Tier 1c (risk score) + Tier 2 (gate + 3 logistics + decision) + Tier 3 (sizing) + tests intégration	Pipeline complet exécutable en standalone, reproductible à partir des notebooks R&D
Sprint 3	6 jobs Cloud Run + crons + Terraform + dashboards GCP + 4 alertes + walk-forward complet	Pipeline tournant en pré-production, tous les outputs en DB, monitoring branché

Critère de fin de BUILD : reproduction stricte des résultats notebooks R&D (HMM persistance, GARCH calibration, edge Tier 2 sous gate) dans l'environnement de pré-production sur la totalité de l'historique 2016–2026. Si écart > 5 % sur n'importe quelle métrique de référence, on debug avant de continuer.

Phase VALIDATION + DEPLOY (après BUILD)

ÉTAPE	DURÉE	ACTION	CRITÈRE PASS
1. Walk-forward + bootstrap CI	2 jours (offline)	5 folds expanding window 2016–2025, bootstrap 5000 itérations stratifié par (gate_active, regime_id) .	Critères pre-registered (cf. § 6) atteints
2. Holdout strict	1 jour (analyse)	Test sur 374 jours holdout (2024-09 → 2026-04). Tier 1 doit rester calibré ; Tier 2 peut se dégrader (acceptable).	Tier 1 calibration $ \text{predicted} - \text{actual} < 0.05$; Tier 2 si actif : delta ≥ 0
3. Shadow nightly	30 jours calendaires	v6.0.0 tourne en parallèle, écrit ses propres rows en DB. Dashboard et brief restent sur l'algo précédent.	Distribution Tier 2 cohérente avec backtest (~70 % MONITOR, ~30 % actif sous gate)
4. Cutover (conditionnel)	Day 31	Flip is_active de l'algo précédent vers v6.0.0.	Phase 3 OK ; calibration Tier 1 maintenue en production
5. Steady-state	Continu	Monitoring 4 axes (régime calibration, GARCH calibration, Tier 2 edge, distribution actions).	Aucune alerte critique pendant 60 jours

SI TIER 2 ÉCHOUE MAIS TIER 1 RESTE CALIBRÉ on déploie quand même — Tier 1 (régime + vol + risque + sizing) a une valeur opérationnelle propre, indépendante de la capacité à prédire la direction. La sortie produit affiche alors « MONITOR » en permanence pour l'action directionnelle, mais le trader continue à utiliser le système pour le sizing inverse vol et les alertes de transition de régime.

Rollback

Identique au schéma standard — transaction SQL :

```
BEGIN;
  UPDATE pl_algorithm_version SET is_active = false WHERE name='tiered' AND
  version='6.0.0';
  UPDATE pl_algorithm_version SET is_active = true WHERE name='<previous>' AND
  version='<v>';
COMMIT;
```

Les 6 jobs `cc-tiered-*` continuent à tourner pour audit, mais le dashboard et le brief reviennent à l'algo précédemment actif. Pour stopper tous les jobs : `gcloud scheduler jobs pause cc-tiered-*`.

Override de sécurité (steady-state)

Plusieurs garde-fous additionnels en production :

- **Risk = CRISIS → action = PROTECT forcé**, indépendamment du Tier 2. Empêche un signal directionnel haussier en pleine crise (corrélation marché extrême, halt de cotation, etc.).
- **HMM non-convergent → fallback regime = Normal**. Comportement le plus conservateur (97 % du temps).
- **GARCH divergent → fallback vol = vol_realized_20d**. Tier 1b ne plante jamais entièrement.
- **Trailing accuracy < 50 % sur 60 jours roulants → désactiver Tier 2 temporairement** (tout passe en MONITOR pour l'action directionnelle, Tier 1 et Tier 3 continuent).

Critères de succès chiffrés

L'architecture en 3 tiers permet une évaluation **découplée** : Tier 1 (régime + vol) doit être calibré, Tier 2 (direction) doit avoir un edge prouvé sous gate. Les deux ont des critères pre-registered distincts, et l'un peut réussir sans l'autre.

6.1 — Pre-registered success criteria

TIER 1 PRIMARY (BLOQUANT POUR DÉPLOIEMENT)

Calibration régime. Pour chaque régime $r \in \{\text{Normal}, \text{Burst}\}$: $|\text{persistence_predicted} - \text{persistence_actual}| < 0.05$.

Calibration GARCH. Régression Mincer-Zarnowitz $\text{realized} = \alpha + \beta \cdot \text{forecast} + \epsilon$ sur 20-day forward : $\beta \in [0.8, 1.2]$, $R^2 > 0.5$, $\text{RMSE} < 0.5 \times \text{mean}(\text{realized_vol})$.

TIER 2 PRIMARY (CONDITIONNEL — PEUT ÉCHOUER SANS BLOQUER TIER 1)

Edge sous gate. Quand $\text{vol_ratio} \geq 1.10$: delta vs Always-HEDGE $\geq +5$ pp avec IC 95% (bootstrap 5000 stratifié) excluant zéro.

Abstention rate. $50\% < P(\text{action} == \text{MONITOR}) < 80\%$ (système sélectif mais pas inutile).

REJECTION GLOBAL. Si Tier 1 mal calibré (les « 97.6 % » sont en fait 80 %) → refus de déploiement. Si Tier 2 échoue ET Tier 1 mal calibré simultanément → pivot complet (acquérir term structure, etc.).

DEGRADED OK. Si Tier 2 échoue mais Tier 1 calibré → on accepte, on déploie en mode « risk-only » (sizing + alertes régime continuent à fonctionner).

6.2 — Validation Tier 1a : calibration régime

Question : quand le système annonce « régime persiste à 97.6 % », est-ce vraiment le cas dans 97.6 % des observations sur le walk-forward ?

```

Pour chaque régime  $r \in \{0, 1, 2, 3\}$ :
    persistence_predicted = transmat[r, r]
    persistence_actual     = mean(regime[t+1] == r | regime[t] == r)
    écart = |persistence_predicted - persistence_actual|

Critère pass : écart < 0.05 pour Normal et Burst (états dominants)
               écart < 0.10 pour Bull (instable, n petit)
               Crash exempt (n=8, sample size insuffisant)

```

6.3 — Validation Tier 1b : calibration GARCH

Test standard Mincer-Zarnowitz sur la régression du réalisé sur le forecast :

```

realized_vol_20d =  $\alpha$  +  $\beta$  · garch_forecast +  $\varepsilon$ 

Critères pass :
     $\alpha \approx 0$       (intercept proche de zéro, pas de biais systématique)
     $\beta \approx 1$        (slope unité, pas d'erreur d'échelle)
     $R^2 > 0.5$         (le forecast explique la majorité de la variance réalisée)
    RMSE <  $0.5 \times \text{mean}(\text{realized\_vol})$  (erreur absolue raisonnable)

```

Tests complémentaires : test ARCH Ljung-Box sur les résidus standardisés ($p > 0.05$, c'est-à-dire pas d'effet ARCH résiduel).

6.4 — Validation Tier 2 : edge conditionnel

Métriques calculées **uniquement sur les jours où le gate est actif** :

MÉTRIQUE	DÉFINITION	TARGET	R&D EMPIRIQUE
Delta vs Always-HEDGE	accuracy_v6 – accuracy_hedge sur fenêtre gate active	$\geq +5$ pp avec IC exclut zéro	+9.1 pp [+3.3, +14.8] (EXP-031)
HEDGE precision (sous gate)	P(down PROTECT signal)	≥ 65 % (vs base ~50 %)	~70 % en walk-forward
Coverage Tier 2	P(action $\neq$ MONITOR gate actif)	≥ 50 % (sinon trop sélectif)	~60 % en walk-forward
Abstention globale	P(action == MONITOR)	50–80 %	~70 % en walk-forward

6.5 — Yearly breakdown (test de stabilité)

Vérifier que Tier 2 ne s'effondre pas en 2025–2026 (rappel EXP-031 : signal directionnel non-stationnaire post-2024). Si Tier 2 s'effondre mais Tier 1 reste calibré, le système conserve sa valeur pour le sizing et les alertes — déploiement en mode dégradé acceptable.

ANNÉE	GATE ACTIVE DAYS	DELTA VS HEDGE (TIER 2)	TIER 1 CALIBRATION OK ?
2018	~70	+12.5 pp	Oui
2019	~50	+8.0 pp	Oui
2020	~85	+3.5 pp (COVID volatil)	Oui
2021	~55	+11.2 pp	Oui
2022	~40	-1.0 pp (sideways)	Oui
2023	~60	+15.0 pp	Oui
2024	~120	+22.0 pp	Oui
2025	~45	+6.0 pp	Oui
2026 (à fin avril)	~15	À mesurer	À mesurer

Note : ces chiffres sont des estimations issues de la R&D EXP-031 / EXP-032 ; les valeurs définitives sortiront de la phase 1 du rollout (walk-forward complet en environnement de pré-production).

6.6 — Alertes monitoring continu (post-cutover)

MÉTRIQUE	PÉRIODE	SEUIL ALERTE
Calibration régime (Tier 1a)	rolling 60 jours	écart $ \text{predicted} - \text{actual} > 0.10$ sur Normal → bloquer prochain retrain HMM
Calibration GARCH (Tier 1b)	rolling 60 jours, MZ regression	β hors $[0.7, 1.3]$ OU $R^2 < 0.4$ → forcer retrain immédiat
Edge Tier 2 sous gate	rolling 60 jours, gate active uniquement	delta < -2 pp pendant 3 mois → désactiver Tier 2 (passe en MONITOR), Tier 1 continue
Distribution actions	rolling 30 jours	$P(\text{MONITOR}) > 90\%$ (gate trop strict) OU $P(\text{action}) > 60\%$ (gate trop lax)

6.7 — Tests d'acceptance pré-deploy (CI)

#	TEST	EXPECTED
1	HMM forward filter reproduction	Distribution régime identique au notebook EXP-005
2	HMM relabel by ascending mean return	regime_id=0 (Crash) a la moyenne return la plus négative
3	GARCH(1,1) calibration MZ	$\beta \in [0.8, 1.2]$, $R^2 > 0.5$ sur historique complet
4	Risk score deterministic	Tous les bins (LOW / ELEVATED / HIGH / CRISIS) couverts au moins 1x sur 10 ans
5	Gate vol_ratio	vol_ratio < 1.10 → action = MONITOR, p_down = NULL
6	3 logistics par régime	3 modèles distincts en DB (Normal / Burst / Bull) ; régime 0 (Crash) → PROTECT hardcodé
7	CRISIS override	risk_level == CRISIS force action = PROTECT, indépendamment du Tier 2
8	Pre-registered criteria sur holdout	Tier 1 calibré ; Tier 2 delta $\geq +5$ pp avec IC exclut zéro

07 · LIMITATIONS

Limitations honnêtes

Aucune ne disqualifie la release individuellement, mais elles cadrent les attentes et orientent le monitoring continu.

LIMITATION 1 — COÛT D'ENGINEERING SIGNIFICATIF (~26 JOURS)

C'est la limitation principale. L'architecture en 3 tiers demande beaucoup plus de surface de code et d'infrastructure que les algos plus simples : 6 jobs Cloud Run, 4 nouvelles tables DB, 3 cadences de retrain à orchestrer, dashboards et alertes par tier. On parle de 2-3 sprints engineering pour une personne dédiée. **Mitigation** : la migration peut se faire par tier (Tier 1 d'abord, Tier 2 après), ce qui permet une livraison incrémentale et une réduction du risque big-bang. Le Tier 1 seul est déjà valable opérationnellement.

LIMITATION 2 — TIER 2 EST CONDITIONNEL — PEUT NE PAS S'ACTIVER PENDANT DES MOIS

Le gate `vol_ratio ≥ 1.10` est actif ~28 % du temps en moyenne historique, mais cette moyenne cache une grande variance. En 2022 (sideways), le gate n'a tourné que ~40 jours sur l'année. Si on entre dans une période prolongée de marché calme (ex. 6+ mois de `vol_ratio < 1.0`), Tier 2 reste en MONITOR continu — l'utilisateur ne reçoit aucun signal directionnel. **Mitigation** : c'est un comportement assumé (« on s'abstient quand on ne sait pas »), mais il faut le communiquer clairement à l'utilisateur. Tier 1 (régime + vol + risque) continue à fournir de la valeur indépendamment.

LIMITATION 3 — NON-STATIONNARITÉ POST-2024 (ALERTE FORTE)

EXP-031/032 ont documenté un signal directionnel non-stationnaire après la rupture de janvier 2024. Le delta sur 2025–2026 est plus faible que sur 2018–2023. Si cette tendance se poursuit, Tier 2 peut s'effondrer en production sans que Tier 1 (régime, vol) ne soit affecté. **Mitigation** : c'est exactement le scénario pour lequel le mode dégradé (Tier 1 only) est prévu. Le système n'a pas besoin de tout réussir pour rester valable.

LIMITATION 4 — RÉGIME BURST SOUS-REPRÉSENTÉ (N=114) ET CRASH (N=8)

Le régime Burst représente 4.4 % des observations. Sa logistique a un ratio obs/params de ~10:1 (juste OK). Le régime Crash, avec n=8, est trop petit pour fitter quoi que ce soit — d'où le hardcoded PROTECT, qui est conservatif mais possiblement faux dans certains crashes spécifiques (un crash de durée longue pourrait inclure des rebonds). **Mitigation** : Crash est rare (0.3 % du temps), donc

l'exposition à des erreurs de Crash est faible. Burst est mieux échantillonné mais à surveiller en steady-state via la calibration des poids logistiques.

LIMITATION 5 — DÉPENDANCE CRITIQUE SUR LA LIB ARCH

Le GARCH passe par `arch ^7.x`, lib Python excellente mais qui devient une dépendance critique de la pipeline. Si `arch` introduit un breaking change ou un bug en production, Tier 1b plante.

Mitigation : (i) pin de version stricte dans `pyproject.toml` ; (ii) fallback automatique sur `vol_realized_20d` si le solver GARCH diverge — Tier 1b ne plante jamais entièrement ; (iii) tests CI qui valident `arch` contre une fixture de référence à chaque PR.

LIMITATION 6 — PAS DE TERM STRUCTURE NI DE CROSS-COMMODITY

Comme tous les algos précédents, `tiered v6` repose uniquement sur les OHLCV du contrat front. Pas de basis (front vs second-month), pas de COT positioning hebdomadaire, pas de corrélations sucre/café. Ces sources sont toutes documentées comme potentiellement valables dans la R&D mais pas intégrées dans les pipelines actuels. **Si Tier 2 échoue sur le holdout**, ce sera le premier endroit où regarder pour la release suivante (estimation +10-15 pp gain potentiel en intégrant term structure ; coût d'intégration : 1-2 sprints data engineering).

LIMITATION 7 — GARCH(1,1) EST UN MODÈLE SIMPLE

On aurait pu choisir GARCH-M (vol-in-mean), FIGARCH (long memory), ou volatilité stochastique (Heston). EXP-027 a montré que GARCH(1,1) suffit pour cocoa daily (résidus ARCH éliminés, $p=0.73$), mais on n'a pas testé exhaustivement les alternatives plus complexes. **Mitigation** : si la calibration GARCH se dégrade en production, c'est le ticket suivant. Pour la release v6, GARCH(1,1) est un choix conservateur et défendable scientifiquement.

Annexes

A. Comptage des paramètres trainables

COMPOSANT	PARAMS	NOTES
HMM 4 états	~24	means(4) + covars(4) + transmat(4×4) + startprob(4)
GARCH(1,1)	3	ω, α, β
Logistic per régime (3 actifs)	$3 \times 3 = 9$	2 weights + bias par régime ; Crash hardcoded
Risk score thresholds	4	vol_pctile et vol_ratio break points
Gate threshold	1	vol_ratio = 1.10 (calibré par sweep EXP-031)
Decision thresholds	2	PROTECT > 0.65, TRADE < 0.35
Total trainable	~36	$n_{\text{eff}}/\text{params} = 1547/36 = 43:1$

B. Format de sortie quotidien (DB row)

L'extension de `pl_indicator_daily` stocke 17 nouveaux champs structurés en 3 tiers :

```

{
  "date": "2026-04-10",
  "contract_id": "<uuid CA_CONT>",

  // == TIER 1 - HIGH CONFIDENCE ==
  "regime_id": 1,
  "regime_name": "NORMAL",
  "regime_probability": 0.94,
  "regime_persistence_1d": 0.976,
  "regime_change_5d": 0.082,
  "vol_forecast_ann": 0.358,
  "vol_forecast_ci_lo": 0.250,
  "vol_forecast_ci_hi": 0.466,
  "risk_level": "LOW",
  "risk_score": 1,

  // == TIER 2 - MEDIUM CONFIDENCE ==
  "gate_active": false,
  "vol_ratio": 0.77,
  "p_down": null,
  "tier2_confidence": null,
  "action": "MONITOR",

  // == TIER 3 - INFO ==
  "atr_high": false,
  "position_sizing_1pct": 0.43,
  "trailing_30d_accuracy": 0.512
}

```

C. Exemple de sortie (jour de transition de régime)

```

== TIER 1 - HIGH CONFIDENCE ==
Régime: NORMAL → ELEVATED [transition détectée]
Persistance NORMAL: 82% (down from 97.6%)
Vol forecast tomorrow: 48.2% ann (CI: [33.7%, 62.7%])
Risk level: ELEVATED [score: 2]
Probabilité de changement régime à 5j: 32%

== TIER 2 - MEDIUM CONFIDENCE ==
Gate: ACTIVE (vol_ratio = 1.18)
P(down): 0.42
Confidence: 0.16 (LOW)
Action: CAUTIOUS

== TIER 3 - INFO ==
MACD: bullish (+14.9), rising
RSI: 65.5 (approaching overbought)
ATR: 52.5 (high)
Position sizing (1%): 0.31x [reduce by 70%]
Trailing 30d accuracy: 53%

```

D. Coût opérationnel (ordre de grandeur)

- **5 nouveaux Cloud Run Jobs nightly** (~3 min cumulé, 512-1024 MiB RAM par job) : ~2 €/mois total Cloud Run.
- **2 nouveaux crons offline** (HMM trimestriel ~15 min, GARCH mensuel ~3 min) : négligeable.
- **3 prefixes GCS** (`tiered/hmm/` , `tiered/garch/` , `tiered/logistic/`) : ~150 KB / an total.
- **4 nouvelles tables DB** : `pl_regime_state` (4 rows/jour $\approx$ 1000 rows/an), `pl_vol_forecast` (1 row/jour $\approx$ 250/an), `pl_garch_model` (12 rows/an), `pl_logistic_model` (extension). Volume total négligeable, < 100 KB/an.
- **6 dashboards GCP + 4 alert policies** : effort de mise en place, coût d'opération négligeable.

E. Output files du training script

FICHIER	CONTENU
<code>output/tiered_v6/daily_signals.csv</code>	Walk-forward outputs (3 tiers complets)
<code>output/tiered_v6/tier1_validation.csv</code>	Calibration régime + GARCH (Mincer-Zarnowitz)
<code>output/tiered_v6/tier2_validation.csv</code>	Conditional accuracy par fold
<code>output/tiered_v6/yearly_breakdown.csv</code>	Performance par année
<code>output/tiered_v6/calibration_curves.png</code>	Vol forecast vs réalisée
<code>output/tiered_v6/regime_timeline.png</code>	Régime + risque sur 10 ans
<code>output/tiered_v6/v6_params.json</code>	HMM + GARCH + Logistics + thresholds

F. Références R&D

EXP	TITRE	FINDING APPLIQUÉ
EXP-001	Dataset profile	Kurtosis +14.58, ARCH effects → GARCH justifié
EXP-005	Formal regime detection	4 régimes HMM, persistence Normal 97.6%, Burst 94.5%
EXP-007	Skill benchmark	Direction unpredictable >52% → pivot vers risque
EXP-008	Feature importance	macd top 1, atr top 4 ; RF accuracy 50.7%
EXP-009	Decision functions	Régime ensemble +3.1pp en high-vol → gate justifié
EXP-010	Short-window features	Delta features +6pp post-rupture
EXP-027	Normalization + GARCH	GARCH(1,1) élimine ARCH, persistence 0.97
EXP-028	Causality (Granger / Transfer entropy)	atr_14d seul TE-significatif → feature centrale
EXP-029	Minimum viable signal	macd+atr +6.9pp, IC=[+1.5, +12.2]
EXP-031	Signal diagnostic	Gate vol_ratio sweet spot = 1.10 (+9.1 pp, IC=[+3.3, +14.8])
EXP-032	Adaptive regime signal	Confirme : signal non-stationnaire post-2024

Documents de référence : docs/EXP033_SYSTEM_DESIGN.md (design original), docs/COMPASS_V2_VS_EXP033_SYNTHESIS.md (comparatif), docs/R&D_CACAO_FINAL_REPORT.md (rapport complet).



COMMODITIES COMPASS · TIERED V6.0.0 · MAI 2026 · CONFIDENTIEL